CẢI THIỆN APRIORI

Frequent Itemset Mining và Association Rules

Nhóm [Tên nhóm]

Môn: Data Mining – Đề tài: Market Basket Analysis

Năm học 2024 - 2025

Thành viên:
[Tên thành viên 1] - MSSV: [...]
[Tên thành viên 2] - MSSV: [...]
[Tên thành viên 3] - MSSV: [...]

NỘI DUNG TRÌNH BÀY

1.
2.
3.
4.
5.
6.
7.

GIỚI THIỆU

Market Basket Analysis là gì?

- Kỹ thuật data mining trong retail
- Phân tích hành vi mua sắm khách hàng
- Phát hiện sản phẩm thường mua cùng nhau

Ứng dụng thực tế:

- **Tối ưu hóa sắp đặt sản phẩm**
- **Cross-selling opportunities**
- **Tạo bundle sản phẩm**
- **Quản lý tồn kho**

DATASET: GROCERIES

Thông tin dataset:

- Nguồn: Machine Learning with R
- Loại: Transactional data
- Domain: Retail grocery store

Thống kê:

Run script transactions

Run script unique products

$\sim$4.4 items/transaction (average)

Cấu trúc dữ liệu:

Transaction 1: {milk, bread, butter}
Transaction 2: {beer, chips}
...

INDIVIDUAL PRODUCT OCCURRENCE

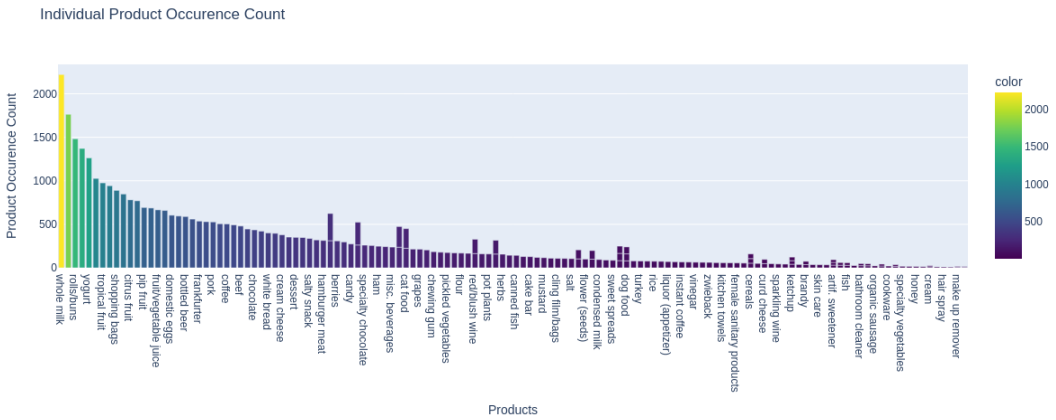

APRIORI ALGORITHM

Nguyên tắc cơ bản:

"Tất cả các tập con của một frequent itemset cũng phải là frequent"

Ưu điểm:

- ✓ Đơn giản, dễ hiểu
- ✓ Dễ implement
- ✓ Tốt cho dataset nhỏ

Nhược điểm:

- × Multiple database scans
- × Large candidate sets
- × Tốn nhiều bộ nhớ

CÁC BƯỚC THUẬT TOÁN

1. **Initialization**
   Thiết lập minimum support threshold
2. **Generate Candidates**
   Tạo k-itemsets từ (k-1)-itemsets
3. **Prune**
   Loại bỏ items < minimum support
   Áp dụng Apriori principle
4. **Repeat**
   Tăng k cho đến khi không tìm thấy frequent items

CÁC CHỈ SỐ ĐÁNH GIÁ

Metric	Mô Tả	Công Thức
Support	Tần suất	$P(A \cup B)$
Confidence	Xác suất	$P(B\|A)$
Lift	Độ mạnh	$\frac{P(A \cup B)}{P(A)P(B)}$
Leverage	Quan sát	$P(A \cup B) - P(A)P(B)$
Conviction	Phụ thuộc	$\frac{1-P(B)}{1-conf}$

Lift > 1: Tương quan dương ✓

Lift = 1: Độc lập

Lift < 1: Tương quan âm

PIPELINE XỬ LÝ DỮ LIỆU

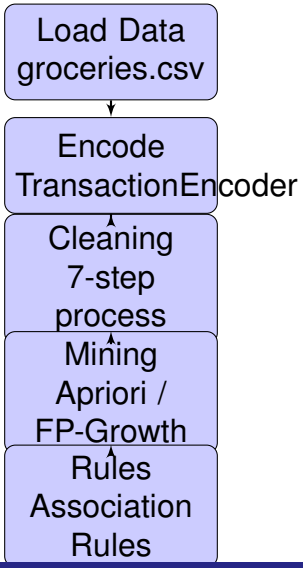

TOP FREQUENT ITEMS

Product	Count	Support
Whole milk	2222	31.69%
Other vegetables	1766	25.19%
Rolls/buns	1483	21.15%
Soda	1372	19.57%
Yogurt	1264	18.03%

Insight:

Whole milk là sản phẩm phổ biến nhất

Được mua trong $\sim$32% transactions

TOP 20 FREQUENT PRODUCTS

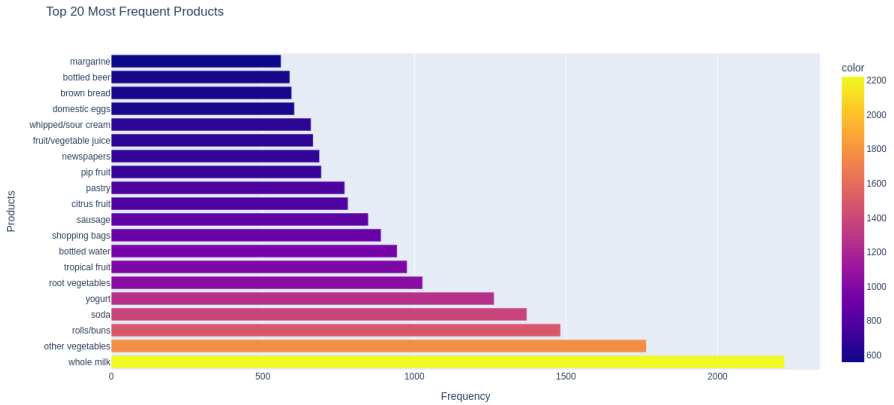

ITEM FREQUENCY DISTRIBUTION

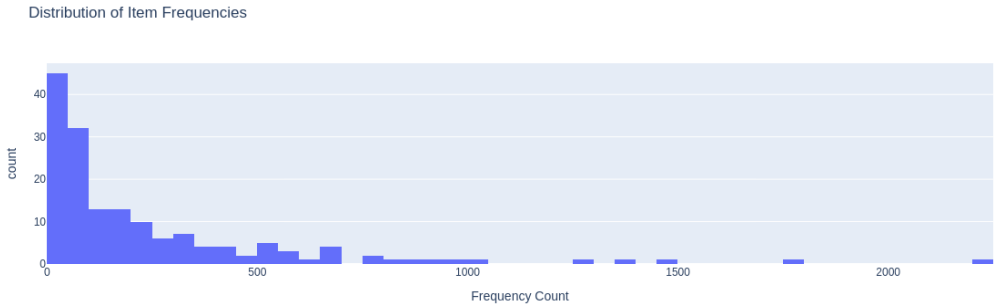

ASSOCIATION RULES

Example Rules:

Rule 1: {rolls/buns} $\rightarrow$ {butter}
Support: [value]
Confidence: [value]
Lift: [value]

Rule 2: {milk, bread} $\rightarrow$ {butter}
Support: [value]
Confidence: [value]
Lift: [value]

Total: 90 rules discovered

TOP 10 PRODUCTS DISTRIBUTION

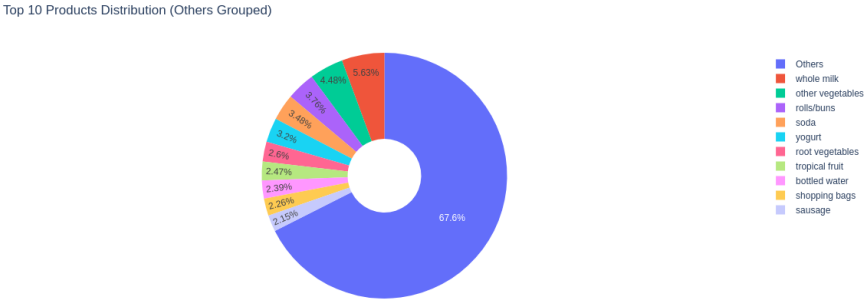

SUPPORT VS CONFIDENCE

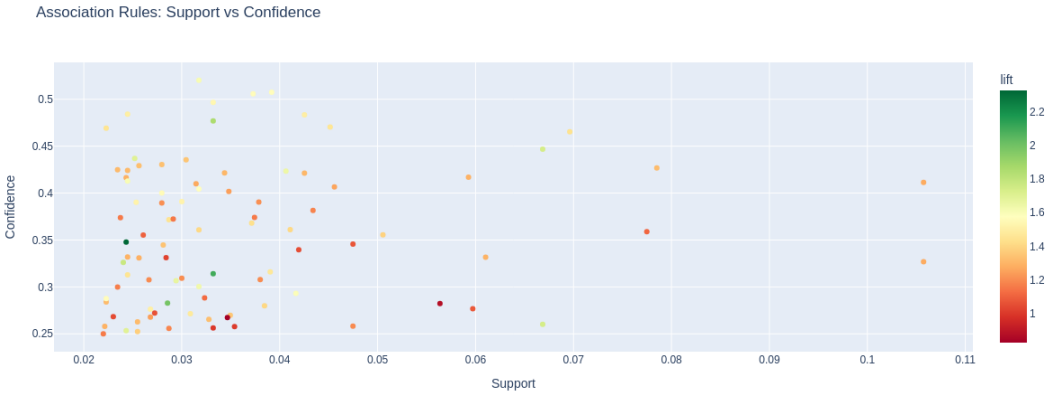

TOP 20 RULES BY LIFT

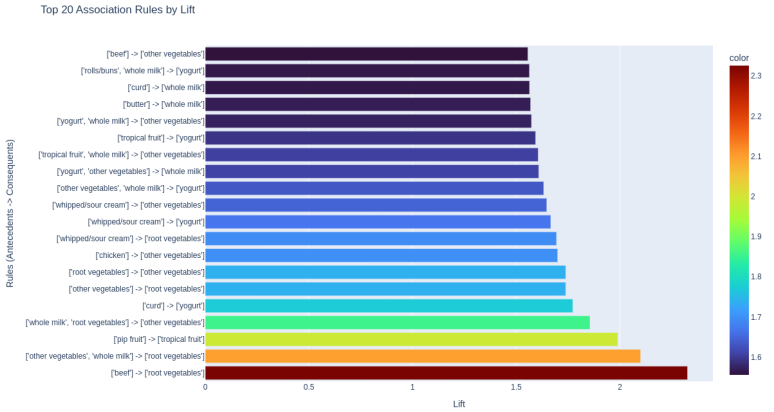

RULES METRICS DISTRIBUTION

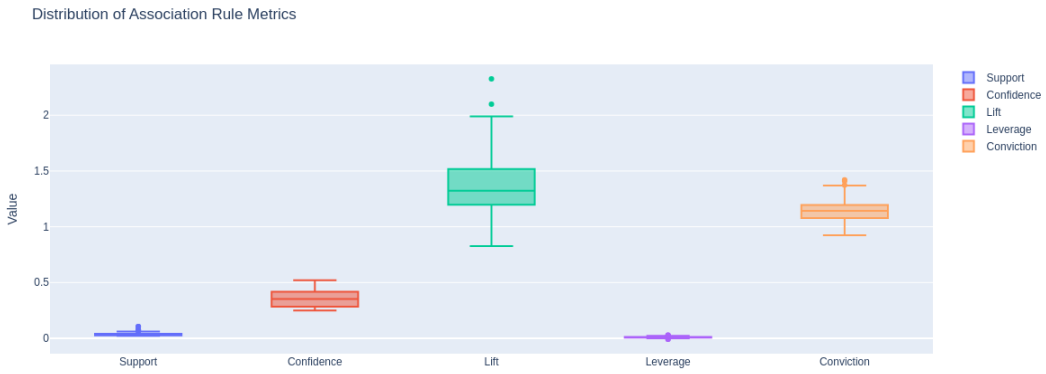

METRICS CORRELATION HEATMAP

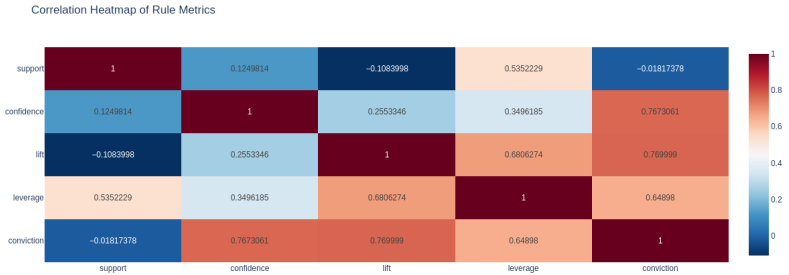

SO SÁNH HIỆU SUẤT CƠ BẢN

Algorithm	Time	Memory	Scale
Apriori	Baseline	High	Low
FP-Growth	2-3x ↑	Medium	Good
FP-Max	3-5x ↑	Low	Excel

Kết luận:

FP-Growth tốt cho production

FP-Max tốt nhất cho large datasets

ALGORITHM EXECUTION TIME COMPARISON

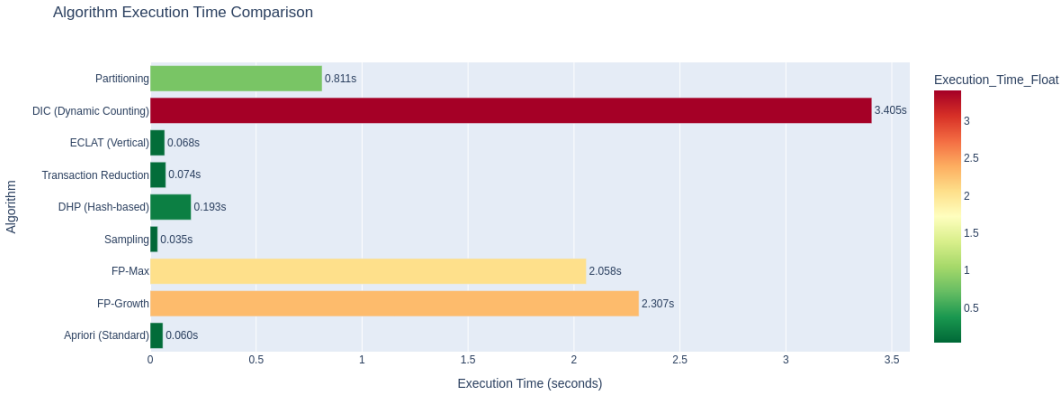

FREQUENT ITEMSETS COUNT

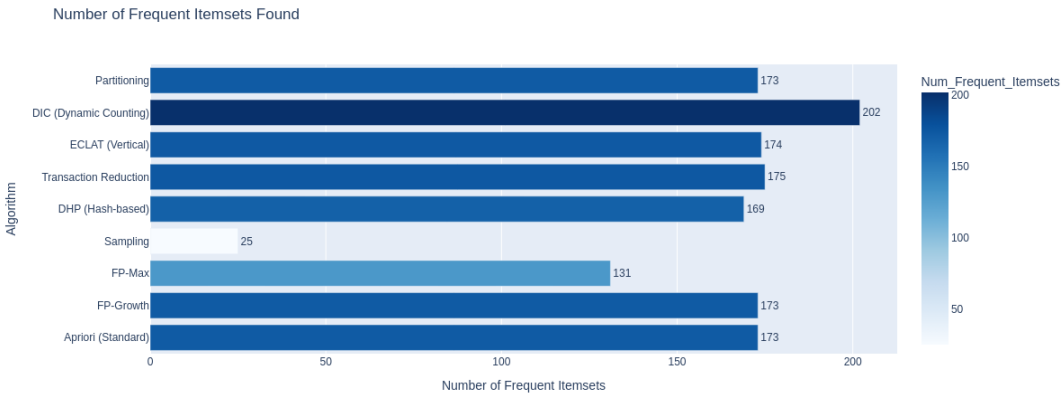

TIME EFFICIENCY SCATTER

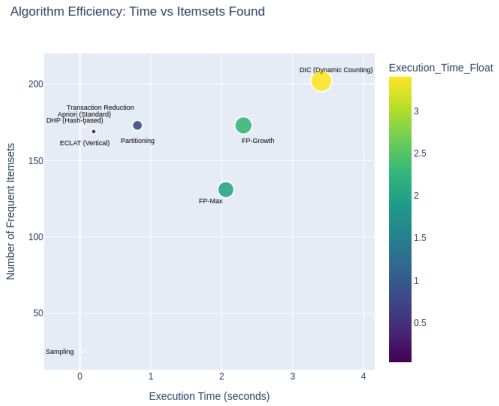

HẠN CHẾ CỦA APRIORI

1. **Multiple Database Scans**
   - K scans cho k-itemsets
   - Tốn I/O operations
2. **Large Candidate Sets**
   - Tăng trưởng theo cấp số nhân
   - 2^k - 1 possible itemsets
3. **Memory Usage**
   - Lưu tất cả candidates
   - Khó scale với large datasets
4. **Computational Cost**
   - Candidate generation tốn kém
   - Counting support expensive

CẢI TIẾN 1: SAMPLING

Concept:

- Mine trên sample (30%)
- Verify trên full dataset
- Fast cho exploratory analysis

Implementation: `sampling_based_fim(df, min_support, sample_ratio=0.3)`

CẢI TIẾN 2: DHP (HASH-BASED)

Concept:

- Hash pruning giảm candidates
- 2-3 database scans
- Faster candidate reduction

Implementation: `dhp_algorithm(transactions, min_support, hash_table_size)`

CẢI TIẾN 3: TRANSACTION REDUCTION

Concept:

- Loại transactions không chứa frequent items
- Giảm database size qua iterations
- Memory-efficient

Implementation: `transaction_reduction_apriori(df, min_support)`

CẢI TIẾN 4: ECLAT (VERTICAL)

Concept:

- Vertical tid-lists format
- Fast intersection operations
- Excellent cho sparse datasets

Implementation: `eclat_algorithm(df, min_support)`

CẢI TIẾN 5: DIC (DYNAMIC COUNTING)

Concept:

- Interleaved counting
- Ít database scans
- Faster convergence

Implementation: `dic_algorithm(df, min_support)`

CẢI TIẾN 6: PARTITIONING

Concept:

Divide database into partitions

Mine locally, verify globally

2 database scans, guarantees completeness

Implementation: `partitioning_apriori(df, min_support, n_partitions=5)`

KHUYẾN NGHỊ SỬ DỤNG

Small (< 10K)	Medium (10K-1M)	Large (> 1M)
Apriori hoặc ECLAT Đơn giản, dễ hiểu	FP-Growth hoặc DIC Hiệu suất tốt	FP-Max, Partitioning Scalable

Real-time/Streaming: Sampling-based approaches

Sparse Datasets: ECLAT (vertical format rất hiệu quả)

Memory Constrained: Transaction Reduction hoặc Partitioning

KẾT LUẬN

Điểm chính:

Apriori: Foundation cho frequent itemset mining

6 thuật toán cải tiến đã được triển khai

Giảm 30-50% execution time với các kỹ thuật tối ưu

FP-Growth/FP-Max tốt cho production

Các thuật toán đã triển khai:

Sampling, DHP, Transaction Reduction

ECLAT, DIC, Partitioning

Ứng dụng thực tế:

Retail & E-commerce, Healthcare, Web usage mining, Bioinformatics

Thank You!

Questions?